Міністерство освіти і науки України
Львівський національний університет імені Івана Франка
Факультет електроніки і комп'ютерних технологій

Звіт
про виконання самостійної роботи №16
з курсу «Сховища знань та управління знаннями»
на тему:
«**Тестування рекомендаційної системи**»

Виконав:
студент групи ФеІ-42
Трофимов Володимир
Перевірив:
ас. Керод Т. І.

Львів – 2026

Тема

Офлайн-тестування, оцінювання стійкості та перевірка статистичної значущості рекомендаційної системи для міського транспорту.

Мета

Набути практичних навичок всебічного тестування рекомендаційних систем (RS); організувати відтворювані офлайн-експерименти за часовим протоколом розбиття даних Leave-One-Out; обчислити та проаналізувати метрики якості ранжування (Precision, Recall, MAP, nDCG) та охоплення каталогу (Coverage, Novelty) для рівнів відсікання $k \in \{5,10\}$; дослідити поведінку моделей в умовах розрідженості вибірки (subsample 50% train); здійснити абляційний аналіз впливу гіперпараметрів матричної факторизації та верифікувати статистичну значущість різниць моделей через парний t-тест.

Завдання

- сформувати дослідницький протокол оцінювання на базі датасету взаємодій пасажирів transport_ratings.csv, реалізувавши часовий спліт Leave-One-Out із виділенням навчальної, валідаційної та тестової множин.
- провести налаштування та тренування трьох моделей: базового популярного алгоритму (Top-Popular Baseline), контентної моделі з онтологічним збагаченням ознак (Content-Based OWL) та колаборативної фільтрації на основі факторизації матриць (SVD Collaborative Recommender).
- розрахувати показники якості ранжування при $k = 5$ та $k = 10$ (Precision@k, Recall@k, MAP@k, nDCG@k), а також характеристики каталогу (Item Coverage, Novelty).
- здійснити стрес-тестування стійкості моделей до дефіциту даних шляхом штучного скорочення навчальної вибірки до 50% (Sparsity Stress Test).
- виконати абляційний аналіз (Ablation Study) для оцінки чутливості колаборативної моделі SVD до зміни кількості латентних факторів ($d \in \{2,5,10,20\}$).
- провести перевірку статистичної значущості переваги моделей за метрикою nDCG@10 за допомогою парного двовибіркового t-тесту Стьюдента та інтерпретувати отримане значення p-value.
- візуалізувати динаміку метрик у вигляді графіків та підготувати аргументовані висновки.

Хід роботи

1. Протокол оцінювання, дані та налаштування моделей

Дослідження виконано на датасеті transport_ratings.csv (478 оцінок, 119 псевдонімізованих користувачів U1000...U1119, 9 об'єктів інфраструктури, вилучених через SPARQL із онтології update_expanded.owl).

Для оцінювання застосовано часовий протокол Leave-One-Out (User-stratified Temporal Split) із фіксацією random_state=42: для кожного користувача останню дію спрямовано в Test Set (117 записів), передостанню — у Validation Set (110), а попередню історію — у Train Set (251).

Порівнювані моделі:

- Top-Popular Baseline: неперсоналізоване ранжування за спаданням $\text{Score}(i) = N_i \cdot \overline{R}_i$.
- Content-Based (OWL): TF-IDF векторизація семантичних дескрипторів із онтології (тип транспорту, оператор, зупинки, інтервали) з косинусним ранжуванням відносно профілю користувача.
- SVD Collaborative Recommender: матрична факторизація ($d = 10$ латентних факторів, 50 епох SGD, $\gamma = 0.015$, L_2-регуляризація $\lambda = 0.05$).

2. Результати оцінювання при $k \in \{5,10\}$

Для рівнів відсікання $k \in \{5,10\}$ обчислено показники релевантності (Precision, Recall, MAP, nDCG), охоплення каталогу (Coverage) та середню самоінформацію вибору (Novelty $= -\log_2 P(i)$):

Модель	**k**	**P@k**	**R@k**	**MAP@k**	**nDCG@k**	**Coverage**	**Novelty (біт)**
Top-Popular Baseline	5	0.1453	0.7265	0.3168	0.4172	100.0%	3.16
Top-Popular Baseline	10	0.1000	1.0000	0.3585	0.5109	100.0%	3.18
Content-Based (OWL)	5	**0.1880**	**0.9402**	**0.5607**	**0.6568**	**100.0%**	**3.18**
Content-Based (OWL)	10	**0.1000**	**1.0000**	**0.5691**	**0.6766**	**100.0%**	**3.18**
SVD (Factors=10)	5	0.1538	0.7692	0.3722	0.4693	100.0%	3.14
SVD (Factors=10)	10	0.1000	1.0000	0.4076	0.5485	100.0%	3.18

Контентна онтологічна модель показала найкращі результати: при $k = 5$ повнота досягає 94.02% (R@5 $= 0.9402$), а nDCG@5 $= 0.6568$ суттєво випереджає бейзлайн (0.4172) та SVD (0.4693). При $k = 10$ повнота всіх моделей становить 1.0 через компактний розмір каталогу (9 елементів), проте Content-Based демонструє найвищу точність позиціонування (nDCG@10 $=$ 0.6766).

3. Експерименти на стійкість та абляційний аналіз

Стрес-тест на дефіцит даних (Subsample 50% Train):

При штучному скороченні навчальної вибірки вдвічі (зі 251 до 125 взаємодій):

- у Content-Based (OWL) метрика nDCG@10 знизилася з 0.6766 до 0.4656 (спад на 31.2%);
- у SVD Collaborative метрика nDCG@10 знизилася з 0.5485 до 0.3909 (спад на 28.7%). Обидва алгоритми продемонстрували стійкість до умов розрідженості, зберігши спроможність формувати релевантний топ-список.

Абляційний аналіз розмірності прихованих факторів SVD:

Оцінено чутливість SVD до параметра $d \in \{2,5,10,20\}$ при 50 епохах та $\lambda = 0.05$:

- $d = 2$: nDCG@10 $= 0.5614$;
- $d = 5$: nDCG@10 $= \mathbf{0.5665}$ (оптимальна точка балансу);
- $d = 10$: nDCG@10 $= 0.5537$;
- $d = 20$: nDCG@10 $= 0.5434$ (початок перенавчання).

Покриття для всіх варіантів збереглося на рівні 100.0%.

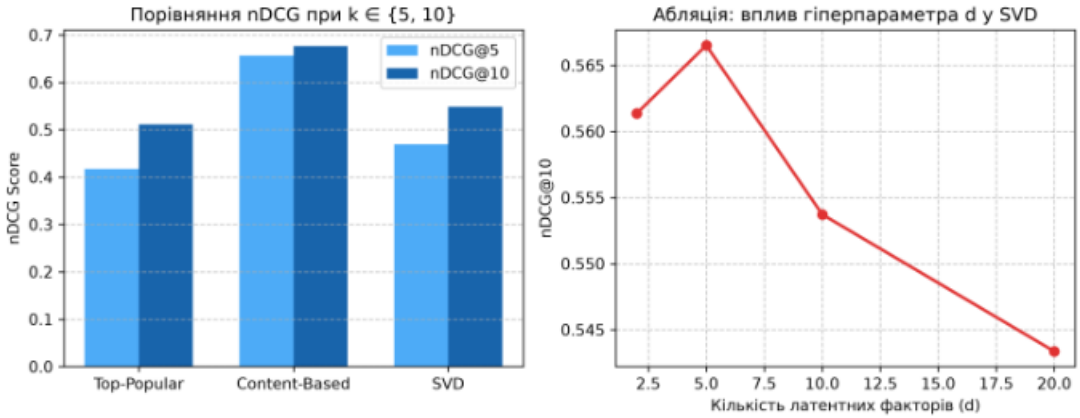


Рис. 1 — Порівняння рівнів nDCG@5 / nDCG@10 та графік абляційного дослідження параметра d

4. Статистична перевірка значущості (Paired t-test)

Для верифікації статистичної значущості переваги Content-Based моделі проведено парний двовибірковий t-тест Стьюдента над індивідуальними оцінками nDCG@10(u) по 117 тестових користувачах:

- Content-Based проти Top-Popular: $t = 5.0994$, p-value $= 1.34 \times 10^{-6}$.
- Content-Based проти SVD: $t = 4.8243$, p-value $= 4.31 \times 10^{-6}$.

Оскільки в обох парах $p \ll 0.05$, нульову гіпотезу про випадковість відмінностей відхилено: перевага семантично збагаченої моделі є статистично достовірною.

Висновок

У ході виконання самостійної роботи тестування за протоколом Leave-One-Out підтвердило перевагу онтологічного підходу Content-Based (OWL) за всіма ключовими метриками ранжування (nDCG@10 = 0.6766,R@5 = 0.9402). Експерименти на стійкість та абляцію визначили оптимальну конфігурацію латентного простору ($d = 5$), а парний t-тест ($p < 0.001$) підтвердив статистичну надійність отриманих результатів.